

PRÉDIRE LA SORTIE D'UNE ENTREPRISE

Probabilité de défaillance et classification des PME

SYNTHÈSE EXÉCUTIVE

Ce projet développe une démarche complète de data science pour estimer le risque qu'une PME cesse son activité dans un horizon de deux ans. À partir de données financières, organisationnelles et territoriales, l'étude construit une cible binaire, prépare les données, sélectionne les variables explicatives et compare trois modèles de classification. L'objectif final est de produire un score de risque exploitable par une banque, un fournisseur, un bailleur ou toute organisation devant évaluer la pérennité d'un partenaire.

1. Problématique métier

Comment anticiper la cessation d'activité d'une PME à partir de ses caractéristiques observables, afin de réduire le risque dans une décision de crédit, de partenariat commercial ou de location professionnelle ?

- Prédire la probabilité de sortie de l'entreprise à deux ans.
- Classer les entreprises entre profils susceptibles de rester actives et profils à risque de sortie.
- Comparer plusieurs approches et retenir le modèle offrant le meilleur pouvoir discriminant.
- Transformer une analyse statistique en outil concret d'aide à la décision.

2. Données mobilisées

Source : original_bisnode_data, base couvrant la population d'entreprises de plusieurs secteurs manufacturiers et de services d'un pays européen entre 2005 et 2016. Les grandes entreprises de plus de 100 M€ de chiffre d'affaires sont exclues de la source.

2012-2014

fenêtre d'étude

< 10 M€

PME retenues

1 935

observations finales

135

sorties identifiées

- Variables financières : ventes, actifs courants, passifs courants, immobilisations, stocks, liquidités, résultat annuel, amortissements, capital souscrit, masse salariale et dépenses de matières.
- Variables de gouvernance et de structure : nombre de dirigeants, part de dirigeants étrangers, localisation urbaine et effectif moyen.
- Cible 'sortie' : 1 lorsque l'entreprise est identifiée comme ayant cessé son activité entre 2012 et 2014, 0 sinon.

3. Préparation et utilisation des données

- 1 Filtrage** - Sélection des exercices 2012 à 2014, des entreprises réalisant moins de 10 M€ de ventes et des structures opérationnelles en 2012 avec plus de 1 000 € de chiffre d'affaires.
- 2 Nettoyage** - Suppression des variables inutiles, traitement des valeurs manquantes, contrôle des valeurs négatives et transformation des variables comptables incohérentes.
- 3 Construction de la cible** - Création de la variable binaire de sortie à partir de l'année et de la date de cessation d'activité.
- 4 Sélection des variables** - Régression logistique et backward selection afin de conserver les caractéristiques statistiquement les plus utiles.
- 5 Modélisation** - Entraînement et comparaison de la régression logistique, du k plus proches voisins (k-NN) et de l'arbre de décision.
- 6 Évaluation** - Analyse des matrices de confusion, de la précision, du rappel et surtout de l'AUC, plus adaptée à une cible déséquilibrée.

4. Solutions testées et résultats

Modèle	Principe	AUC	Lecture
k-NN	Classe selon les profils voisins	0,733	Meilleur pouvoir de classement
Régression logistique	Estime une probabilité interprétable	0,672	Bon modèle de référence
Arbre de décision	Règles simples et explicables	0,626	Lisible mais moins discriminant

Résultat principal. Le k-NN obtient la meilleure AUC (0,733), devant la régression logistique et l'arbre de décision. Il constitue donc la solution la plus performante parmi les modèles testés pour ordonner les entreprises selon leur risque de sortie.

LECTURE CRITIQUE

L'échantillon est fortement déséquilibré : 135 sorties contre 1 800 non-sorties. Une accuracy proche de 93 % peut donc masquer une détection insuffisante des entreprises réellement sortantes. La suite logique du projet consiste à ajuster le seuil de décision, pondérer les classes ou tester du rééchantillonnage, puis à suivre le rappel, le score F1 et la courbe précision-rappel en complément de l'AUC.

5. Conclusion et valeur du projet

Ce projet montre qu'un ensemble de données comptables et organisationnelles peut être converti en score de risque pour soutenir une décision métier. Il couvre l'ensemble de la chaîne analytique : compréhension du besoin, préparation des données, construction de la cible, sélection de variables, modélisation supervisée, comparaison de performances et interprétation critique.